

南开大学

本科生毕业论文（设计）

中文题目：大语言模型的网站访问安全问题研究
外文题目：A Study on the Security Issues of Website
Access in Large Language Models

学号：2111885
姓名：伍泓铮
年级：2021 级
专业：信息安全、法学双学位班
系别：信息安全系
学院：密码与网络空间安全学院
指导教师：李想 副教授
完成日期：2025 年 5 月

关于南开大学本科生毕业论文（设计）的声明

本人郑重声明：所呈交的学位论文，是本人在指导教师指导下，进行研究工作所取得的成果。除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人创作的、已公开发表或没有公开发表的作品内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。本学位论文原创性声明的法律责任由本人承担。

学位论文作者签名：



2025 年 5 月 18 日

本人声明：该学位论文是本人指导学生完成的研究成果，已经审阅过论文的全部内容，并能够保证题目、关键词、摘要部分中英文内容的一致性和准确性。

学位论文指导教师签名：



2025 年 5 月 18 日

摘 要

当前，问答式的大语言模型在互联网环境中的部署与应用使得这些模型具备了与网络环境进行交互的能力。基于用户的指令，模型对网络信息的检索、筛选，乃至对特定网站的访问、提取都有可能产生危及网络安全的问题。本文聚焦大语言模型在网站访问安全方面所表现出的特征与能力，阐述与之相对的隐患，并为该领域的网络安全的防护提供经验与建议。

在大语言模型的网站访问安全方面，无论是用户访问部署模型的网站，还是模型通过链接访问外部网站，都可能造成一定的风险。本文收集并测试了 26 个国内外常见的大语言模型，证实了相关隐患的存在，即利用大语言模型普遍具备的访问外部链接的能力以及存储历史信息和历史文件的能力，通过将传输数据包装成网址链接、对话信息或是文件内容，可以实现低成本、具有实用性的隐蔽数据传输方式。此类漏洞的存在可能导致大语言模型被用于恶意网络活动。

为了更好地说明大语言模型的网站访问安全问题，本文开发了一个以大语言模型为中介平台的可视化应用程序。该程序以 Playwright 网页自动化架构为基础，利用部署在公共网络环境中的大语言模型豆包，在访问外部链接、访问历史信息以及访问历史文件这三种途径上，均可以隐蔽、高效地实现接收端和发送端的数据传输，充分说明了该方法的实用性和潜在的危险性。

关键词：大语言模型；网站访问安全；网络环境交互；数据传输

Abstract

Currently, the deployment and application of question-answering large language models (LLMs) in internet environments have endowed these models with the capability to interact with the web. Based on user instructions, the retrieval and filtering of online information by these models, as well as their access to and extraction from specific websites, may pose risks to cybersecurity. This paper focuses on the characteristics and capabilities of large language models in terms of website access security, elaborates on the corresponding vulnerabilities, and provides insights and recommendations for cybersecurity protection in this field.

In terms of website access security for large language models, risks may arise both when users access websites hosting these models and when the models access external websites via links. This paper collects and tests 26 commonly used large language models, both domestic and international, confirming the existence of related vulnerabilities. Specifically, by leveraging the models' general ability to access external links and store historical information and files, low-cost yet practical covert data transmission can be achieved by disguising data as URL links, conversation content, or file attachments. The presence of such vulnerabilities could allow large language models to be exploited for malicious cyber activities.

To better illustrate the website access security issues of large language models, this paper develops a visual application that uses LLMs as an intermediary platform. Based on the Playwright web automation framework, the application leverages Doubao, a publicly deployed model, to demonstrate that covert and efficient data transmission between senders and receivers can be achieved through three channels: accessing external links, retrieving historical information, and accessing historical files, which fully demonstrates the practicality and potential dangers of such methods.

Key Words: Large Language Models; Website Access Security; Network Environment Interaction; Data Transmission

目 录

摘要.....	I
Abstract.....	II
目录.....	III
第一章 引言.....	1
第一节 研究背景.....	1
第二节 研究思路.....	2
第三节 研究现状.....	3
1.3.1 大语言模型工具及其功能	3
1.3.2 大语言模型的网络安全问题	4
1.3.3 隐蔽传输方案	6
第四节 论文工作.....	8
第五节 论文组织结构.....	9
第二章 攻击概述.....	10
第一节 攻击渠道.....	10
2.1.1 人工页面交互	10
2.1.2 API 交互	11
2.1.3 模拟网页交互	11
第二节 攻击对象.....	12
2.2.1 访问外部链接	12
2.2.2 访问历史信息	12
2.2.3 访问历史文件	13
第三章 大语言模型服务功能分析.....	14
第一节 功能测试.....	14
第二节 初步分析.....	16
第四章 数据传输测试.....	17
第一节 API 测试	17
第二节 页面交互测试.....	18
4.2.1 访问外部链接	19
4.2.2 访问历史信息	21
4.2.3 访问历史文件	21
第三节 模拟网页测试.....	22
4.3.1 访问外部链接	22
4.3.2 访问历史信息	24

4.3.3 访问历史文件	26
第五章 平台成果.....	28
第一节 成果概述.....	28
第二节 性能测试.....	29
第六章 结语.....	32
参考文献.....	34
致谢.....	36

第一章 引言

第一节 研究背景

现如今，大语言模型（Large Language Model, LLM）已然成为自然语言处理领域乃至整个计算机科学领域的前沿话题。在全球范围内，OpenAI 推出的 GPT 系列模型备受瞩目，其中 GPT-3 与 GPT-4 凭借其卓越的性能脱颖而出。GPT 系列基于 Transformer 架构，使用海量文本数据开展自监督学习，深度掌握了对人类语言的理解能力，其数十亿乃至上万亿的参数成功构建了覆盖从基础文本处理至复杂任务执行的庞大能力集合。它们不仅能够实现如自然语言的生成与解析等基础性任务，还在其他不同领域的任务中有着相当优秀的表现，其能力范围涵盖文本创作、知识问答、多语言转译、情感研判、逻辑推演等等。与此同时，谷歌的 PaLM 系列与 Gemini、Meta 的 LLaMA、Anthropic 的 Claude，以及 Mistral AI 等新锐企业产品，也各自构建了独特的技术体系，它们的产品在模型规模、运行效率或语言理解能力维度各有所长，在近三年（从 2021 年起）相继成型，共同构成了大语言模型的技术版图。

我国的国产大语言模型产业同样呈现出蓬勃发展的态势，如 DeepSeek、通义千问和智谱清言等代表性模型相继涌现。相较于国际上的同类型产品，国产模型在中文语境适配、文化理解与对话风格塑造方面具备显著优势。这一方面是由于共同的语言和文化所塑造的天然优势，另一方面也体现了我国当前科研与创新能力的腾飞。这些优势使得国产大模型在语言类的实际工作场景中表现亮眼，已经广泛应用于政务服务、金融分析、法律事务、教育教学领域。

当下的大语言模型市场不仅在模型数量上颇具规模，从功能维度审视，现有的先进模型也呈现出了通用性、多元化的能力特征。所谓通用性，就是大语言模型的功能不仅能够应用于单一行业、单一领域，其语料库具有知识的全面性。所谓，多元化，是指模型本身的功能多样，能够实现的任务广泛。例如，在自然语言生成与理解层面，许多大语言模型不仅支持问答交互、写作辅助及系统对话，还能胜任各种语言风格的转换、内容摘要的提取与生成、情感倾向分析等等；在信息处理领域，模型能够更高效地识别文本关键信息，提取实体关系并生成结构化报告；此外，值得关注的是，随着模型逻辑推理能力的持续强化，众多大语

言模型在数学问题求解、因果关系分析和分步逻辑演绎等任务中，展现出了强大的“思维链”推理能力；更值得一提的是，部分模型集成了联网与工具调用功能，能够自主访问网页资源、执行信息检索或是调用外部工具，这使得大语言模型从单纯的语言处理工具进化成了兼具任务规划、资源协调和结果输出的智能服务代理，而这一转变又催生出了记忆存储和状态更新等适配功能。

综上所述，如今的大语言模型已经突破了传统的语言工具的范畴。通过集成代码解释、数值计算、知识图谱构建与数据库操作等功能模块，大语言模型模型构建起了一个由语义驱动的任务执行框架。它能在其能力的范围内代替人类进行各种操作。从早期的文本生成，到如今的代码编写、指令执行、联网搜索，大语言模型功能的持续拓展与其代理能力的增强说明了它在信息系统、网络空间环境与产业应用场景中的巨大潜力，但这也为深入研究其在复杂环境下的潜在安全风险奠定了技术与现实基础。

第二节 研究思路

在最近涌现的大语言模型的新功能、新应用中，有一种功能尤为特殊。这些通过海量数据训练而成的模型如今不仅能高效地完成文本生成、信息检索和对话交互等对大语言模型来说相对“传统”的任务，如今它们还初步具备了与外部环境进行实时交互的能力。这些部署在公共网络中的模型能够遵照用户的指令，利用网络搜索、筛选新闻信息、提取内容，模拟用户的行为执行特定操作，与互联网进行实时交互。

模型的新功能，毫无疑问可以为智能化应用的创新与网络交互模式的变革提供先进的技术支持。然而，正是由于大语言模型在公共网络环境的大规模部署，由此衍生的安全隐患也开始显现。从数据隐私与网络安全维度来看，大语言模型的应用可能存在多重风险：在处理敏感或隐私数据的过程中，模型的设计缺陷或是用户的恶意操控有可能使模型受到诱导、攻击，进而泄露未经授权的信息；模型与网络环境的交互特性容易被恶意利用，攻击者可能借助模型传播有害内容或是发动对网络目标的攻击；部署于公共网络的模型系统本身也可能被身份伪造或恶意指令注入等形式的攻击所操控。这些问题不仅可能威胁模型用户的隐私与数据安全，对更大范围的网络安全也有着不可低估的影响，是一种不稳

定的因素。所以，研究大语言模型，尤其是部署在公共网络的模型的网络安全特性，揭示其潜在风险，探索其防护策略，具有重要的理论意义与现实价值。

本研究以大语言模型为媒介的网站访问问题，以及之后可能存在的数据传输问题为研究对象。因为利用大语言模型进行网站访问就是检测模型对网络环境安全性影响的一种方式。倘若模型能够替代用户访问网站，这一过程本身就构成了有效的身份隐藏途径。而进入网站后，利用大语言模型实现数据传输或信息提取就是一种天然的、低成本、低风险的数据传输方法。其次，部署于公共网络的大语言模型网站本身也存在潜在的被恶意利用风险。

在实验环节，本研究通过设计一系列测试方案和相应的程序，模拟数据传输过程，希望能通过数据传输的实现直观地呈现这种新型网站访问形式的安全风险，从而完成对相关问题的评估。

第三节 研究现状

1.3.1 大语言模型工具及其功能

当前学界对大语言模型的功能研究仍集中于自然语言处理领域，通过观察现有模型的语义分析和文本生成能力，对模型的性能加以改进。然而，本研究认为，对于部署在公共网络的大语言模型，它们所具备的其他特征同样值得关注。

大语言模型融入网络，为公众、企业所熟悉、应用其实存在一个特定的契机。这个契机就是以 ChatGPT-3 为首的聊天机器人在互联网上引发的讨论与关注。聊天机器人（Chatbots）指的是那些与用户进行对话，获取、理解自然语言，并将相应的自然语言内容反馈给用户的应用模型。很明显，它们最容易使用户感到熟悉与便利。文森等人^[1]在有关大语言模型问答技术的综述中指出，当前的大语言模型已经可以更高效、准确地理解人类提出的复杂语义问题。这是它们为用户进行智能问答、文本生成的技术原理。尽管大语言模型的知识表达能力无法涵盖所有领域知识，导致大语言模型存在着一定的知识盲区，降低了特定领域问答的准确性。但是，在模型不断的迭代、训练下，大语言模型的问答技术已经取得了足够的进展。从专门系统到通用系统，从简单事实问答到复杂推理问答，它们可以端到端地分析文本问题并产生自然流畅的答复，其处理能力、覆盖范围与交互智能性正在不断提升，朝着模拟人类真实问答过程的终极目标持续演进。

大语言模型的信息检索技术也是整个模型功能集合的重要元素。赵鑫等人^[2]发现,大语言模型所带来的能力跃升对于信息技术的发展产生了重要影响,有望深刻改变人们获取信息的方式,促进信息获取技术的更新升级。与相同搜索引擎不同,大语言模型的信息检索技术具有以下几个特征:它能够有效应对复杂用户信息的理解需求;它能够有效处理复杂文档信息的语义表示;它能够完善相关度匹配和结果排序;它还能面向检索结果进行答案抽取与摘要生成;研究者甚至预测,大语言模型的信息检索技术能有效解决当代学术界和工业界难以处理的信息过载问题,大幅提升人类获取信息的能力和效率。目前,大语言模型在信息检索上的研究方兴未艾,未来可探索的空间还比较宽广。

上述提到的问答技术和信息检索技术,实际上就是大语言模型与用户、与公共网络进行实时交互的基础功能。唯有了解它们的原理和特征,才能对模型的网络安全问题形成一个初步的认识。

1.3.2 大语言模型的网络安全问题

在全球范围内,对由大语言模型衍生而来的安全议题的重视并非个例,相关研究的范畴覆盖生成内容伦理规范、模型行为调控等多个维度。

在国内,虽然豆包、通义千问和 DeepSeek 等国产大语言模型在各方面都展现了卓越的性能,但是国内学术界相关安全领域的研究却呈现明显的滞后态势。针对大语言模型的网络安全问题、模型访问网站时具备的行为特征以及潜在攻击途径等关键方向的学术探索更是尚处于起步阶段。比如付翔等人^[3]和付志远等人^[4]的研究重心偏向模型对舆论生态和社会责任的影响,主要探讨大语言模型应用于互联网这一现象可能产生的社会问题,既未深入挖掘技术层面的漏洞缺陷,也缺乏实证数据与实验验证支撑。而其余研究大多聚焦大语言模型的内容生成问题,重点探索如何降低虚假信息、歧视性内容以及错误表述的生成概率。

近几年国内众多的网络安全领域的研究中,“越狱攻击”(Jailbreak Attacks)是一个重要的题目。越狱攻击指的是攻击者通过设计的提示词(prompt),绕过模型的安全限制,诱导模型生成不应允许的内容。越狱攻击的原理在于利用模型的两种弱点:一是“目标冲突”,即模型在遵循指令和确保内容安全之间的矛盾;二是“泛化缺陷”,由于安全训练无法覆盖所有可能的攻击场景,因而留下了漏

洞。攻击者可能使用编码（如 Base64）来隐藏敏感请求，或是诱导模型扮演虚构角色、假装有权限、切换对话背景来绕过限制。更严重的是，攻击者还可能反过来在模型的辅助下生成更加复杂、准确的攻击指令，提高攻击的成功率和效率。

李南等人^[5]总结了针对大语言模型的三种类型的越狱攻击形式：人工设计的攻击指令、由其他模型自动生成的攻击指令，以及通过算法优化实现的对抗性输入。这些攻击揭示了当前网络安全技术（如人类偏好对齐）的局限性。当模型具备联网功能或是部署在公共网络中时，很容易成为攻击目标。另外，该研究还发现，模型的规模越大，它对越狱攻击的敏感性可能越高。这说明功能更强大的模型可能带来更大的安全风险。模型的这种特征被命名为“逆缩放”特性。

在大语言模型的网络安全问题研究领域，外国的学术界一直走在前列。2021 年，Carlini 等人^[6]的研究就指出，当模型调用外部资源时，存在泄露敏感信息的隐患；Xia 等人^[7]开发的 Fuzz4All 工具则展现出通过大语言模型生成和变异输入，实现多编程语言及功能模糊测试的创新方法。当前国外的相关研究主要围绕隐私保护、恶意网站识别以及访问行为审计展开，部分研究还基于沙箱机制与权限控制提出了一些解决方案。不过随之而来的困境是，如何在保障模型高效运行的同时降低其潜在的安全风险，在其中寻求某种平衡——这其实是网络安全领域的共性挑战，并非大语言模型技术所独有。

Carlini 等人的成果为剖析大语言模型的安全风险提供了重要参照。该团队以 GPT-2 为研究对象，运用“训练数据提取攻击”的手段，通过生成海量文本样本，筛选低困惑度的相似序列，在无需掌握训练数据细节的情况下，成功获取了敏感信息。研究证实，攻击者借助精心构造的查询语句，能够从模型训练数据中提取出原始文本片段，包括个人身份信息（如姓名、联系方式、电子邮箱）、代码片段，甚至是 128 位的唯一标识符（如 UUID）。令人惊讶的是，即便这些信息仅仅在训练数据中出现过一次，模型仍有可能将其“记忆”并泄露。Carlini 等人的研究还发现，模型规模与功能呈正相关，规模越大、功能越强，保留训练数据的可能性也越高，遭受此类攻击的风险也随之增大，这与李南等人提到的“逆缩放”特性一致。研究的最后，Carlini 等人强调开发更强大的防护措施的重要性，建议采用差分隐私或数据去重技术，以降低数据泄露的风险。这一研究不仅为大语言模型的安全部署提供了关键参考，也为平衡模型性能与安全防护提供了重要思路。当然，该研究利用的仍然是大语言模型的内容生成或记忆能力。

总的来说，国内外针对大语言模型的功能开发阶段的研究较为成熟。从实际的模型普及、应用情况出发，可以说大语言模型的发展愈发蓬勃。但是与之相对，在大语言模型的网络安全领域，尤其是在与模型的网站访问相关的领域存在一定的空白。在网络安全方面，国外的研究注重隐私与防御，国内的研究偏重内容生成安全，但均缺乏对访问行为的具体研究和实验验证。这是可以理解的，毕竟大语言模型在社会和网络上的广泛应用尚未完全铺展开。

1.3.3 隐蔽传输方案

本文通过设计隐蔽数据传输方案来揭示大语言模型在网络环境中的安全漏洞，因此有必要总结当前学界在隐蔽传输方案方面的研究进展。国内外的信息安全研究人员在数据传输领域早已开发出多种隐蔽传输方案，基于加密协议、隐写术或模型特性等前沿技术的成果层出不穷。

国内的郁昱等人在安全多方计算协议领域取得了显著成果。例如 Cui 等人^[8]和 Liu 等人^[9]的论文中，就分别提出了高效的加密传输协议。这些协议通过优化“半门”技术和“布尔电路”设计，大幅降低了通信和计算成本，同时确保了数据在多方计算中的安全性。他们的方法在双工网络环境下实现了高效的隐蔽数据传输，适用于隐私保护和分布式系统中的安全通信场景。虽然这些研究未直接涉及大语言模型，但其加密传输的理论和框架为隐蔽数据传递提供了重要参考，可为大语言模型在网络环境中的安全设计提供启发。

在涉及大语言模型的数据传输方向上，Wei 等人^[10]的研究成果备受瞩目。该研究提出了一个针对提示学习（Prompt-Tuning）的后门防御方案，探索如何借助大语言模型的提示机制来保障数据传输的安全。提示学习是大语言模型一种的高效微调技术，它通过在输入端添加特定提示以引导模型输出，而无需调整整个模型的参数，在资源受限场景下极具实用性，尤其是如今模型的参数愈发庞大。但是这一技术也带来了一定的安全风险。攻击者可植入“任务无关后门”（与目标任务无关的恶意提示）干扰模型行为，诱导模型泄露敏感数据或是执行未经授权的操作。Wei 等人发现，此类后门攻击可用于数据传输，即攻击者可以通过精心设计的提示，将敏感信息嵌入模型输出，由接收端解析提取。

为抵御该威胁，研究团队开发出了 LMSanitizer 工具。该工具专门用于检测、

过滤可疑提示，以此防范后门攻击。LMSanitizer 的原理在于利用大语言模型的语义理解能力，通过分析输入提示的语义特征与上下文相关性，识别可能触发后门行为的异常指令。具体操作时，LMSanitizer 先对输入的提示进行预处理，提取语义向量，再与预定义的安全提示模板比对，如果提示偏离正常任务模式（包含无关指令或者异常语义），系统便会自动拦截或修正。Wei 等人的研究以 BERT 和 T5 等模型为测试对象，结果显示，LMSanitizer 在多种后门攻击场景下效果显著，能在不显著影响模型性能的前提下，将后门攻击的成功率降低 90% 以上。

这项研究巧妙地运用了大语言模型的语义处理与上下文理解能力，将提示学习从单纯的任务优化工具转化为安全防御机制。在数据传输的场景中，LMSanitizer 能够拦截绝大部分恶意提示，切断攻击者利用提示机制隐藏数据的路径，为模型的安全部署提供保障。不过，该研究主要聚焦后门防御，尚未探索如何利用大语言模型除提示学习之外其他的特征实现隐蔽传输，也没有说明这种隐蔽传输具体是如何实现的，这为后续的研究留下了一定的空间。毕竟，作为功能复杂的智能系统，大语言模型平台存在多种可被利用特征。

在国外，Witt 等人^[1]提出了一种基于最小熵耦合的隐写术算法，该算法直接利用了大语言模型的内容生成能力，实现了基于模型的隐蔽数据传输。隐写术是一种将秘密信息嵌入文本、图像等载体以隐藏其存在的技术。Witt 等人将这一传统的信息隐藏方法与生成模型相结合，大幅提升了隐写术的隐蔽性与实用性。该研究以 GPT-2 为主要测试模型，实现的算法旨在将秘密信息嵌入模型的生成文本，同时成功保持了文本内容的自然性与质量，不会因为暴露出的隐藏特征被检测工具或者人类察觉。

该算法基于“最小熵耦合”原理，通过调整模型的输出概率分布，将秘密信息编码为特定词序列，从而实现目标文本的生成。算法的具体流程为：发送端将秘密信息（如二进制数据）分解成小片段，利用 GPT-2 的条件生成机制，在生成每个词时依据秘密信息的内容从概率分布中选取特定候选词，经最小熵耦合算法确保生成文本在统计上与正常输出之间不存在过多差异。接收端预先共享解码密钥，只需分析文本词序列即可提取出隐藏信息。实验生成的文本通过了多种隐写检测工具的测试，而且该算法在文本隐写术中的隐藏容量达到了每千字节数位，远超传统隐写术的容量。

Witt 等人的研究充分利用了大语言模型的内容生成能力与概率建模特性，前

者使模型能够产出自然文本作为隐写载体，后者可以精准控制输出分布以嵌入目标信息。此外，该方法支持多模态扩展，能将信息隐藏于模型生成的音频或图像中。不过，该研究也指出了潜在的挑战，这一新式隐写术的效果依赖模型生成内容的质量与隐蔽性。模型的规模和训练数据的分布决定了隐写的容量和安全性。只要部署了基于统计分析的隐写检测器，其效果便会大大削弱，技术无疑需要进一步的优化。但不可否认的是，Witt 等人的工作为基于大语言模型的隐蔽传输方案提供了创新思路，也为本文的相关测试和数据分析提供了重要参考。

郁昱等人的加密协议为数据的安全传输奠定了理论基础，Wei 等人和 Witt 等人的研究则展示了利用大语言模型的提示学习或内容生成能力实现隐蔽数据传输的可能。然而，尽管在安全多方计算和隐写术等领域，学界和工业界对大语言模型的功能利用已经积累了丰富的技术与实验成果，基于大语言模型的隐蔽数据传输仍留有大量空间，亟等更多研究涉足。本文所提出的基于模型网站访问特征的方案就是之前的学者未曾论及的。

第四节 论文工作

互联网平台上大语言模型的广泛部署同其在网络安全领域的研究的不足——这种现象之间的矛盾凸显了以模型的网站访问能力、功能特征及潜在漏洞为研究对象的重要性。本文以此为目标，设计了一种隐蔽数据传输方案，以验证这些漏洞的可利用性和潜在风险。

本文首先提出按照攻击渠道和攻击对象进行分类的研究框架，将人工页面交互、应用程序编程接口（API）交互和模拟网页交互作为三种攻击渠道，将访问外部链接、访问模型存储的历史信息和访问模型存储的历史文件作为三种攻击对象，设计针对大语言模型的测试实验，验证其访问能力和信息存储功能。随后，本文收集并测试了 26 个国内外商用的通用类大语言模型，逐一评估其在网络搜索、HTML 解析、JSON 处理、历史记录访问、独立链接访问和文件传输这六项指标上的表现，以分析其功能特征。测试结果显示，近半数模型在一种或多种攻击对象上均存在可被利用的漏洞。

确认漏洞存在后，本文通过将数据封装为网址链接、对话内容或文件内容，设计并实现了基于大语言模型的隐蔽数据传输方案。最终，在人工页面交互和模

拟网页交互这两种渠道上取得了成功。在人工页面交互测试中，5 个模型能通过外部链接访问网站，22 个模型能存储历史对话信息，19 个模型能存储历史文件；在模拟网页交互测试中，本文开发了 4 个通过外部链接访问网站传输数据的自动化程序、4 个利用历史对话信息传输数据的程序，以及 1 个利用历史文件传输数据的程序。

为了更加直观地展现大语言模型的网站访问安全问题，本文在 Playwright 网页自动化框架的基础上搭建了一个基于豆包模型的可视化应用程序。该程序在公共网络环境下，可以借助豆包模型访问外部链接、访问历史信息与访问历史文件的功能实现隐蔽、高效的数据传输。研究成果证实了研究思路的可行性，也暴露了研究对象对于网络环境的威胁。最终，经过上述测试以及后续的数据分析，本文提出了对大语言模型网站访问问题的综合见解和防范建议。

第五节 论文组织结构

本文按照以下结构展开：在引言部分，本文概述了大语言模型的应用现状以及学界在网络安全领域的研究现状；第二章攻击概述阐述了对模型实施的攻击类型及其原理，旨在暴露大语言模型在网络环境中的潜在缺陷；第三章大语言模型服务功能分析介绍了基于不同攻击对象的测试及初步的结果分析，总结了各模型在访问和存储功能上的特征；第四章数据传输测试详细描述了通过不同攻击渠道利用模型功能，实现隐蔽数据传输的具体方法及实验成果；第五章平台成果介绍了集成各项成果的豆包模型可视化应用程序及其性能测试结果；结语部分基于实验成果，提出了对大语言模型功能开发与应用的安全建议，为未来的研究和模型部署提供指导。

第二章 攻击概述

利用大语言模型的网站访问功能及其潜在漏洞，并在此基础上设计数据传输实验以评估其能力的方式，可以被称作对大语言模型的一种“攻击”。于是，为了系统研究这些攻击，可以按照攻击的渠道对象进行分类——这种分类首先建立在假设之上，需要设计后续实验进行验证。根据攻击渠道的不同，即与大模型产生交互的方式不同，可分为人工页面交互、应用程序编程接口交互，以及使用网页自动化技术模拟网页交互；根据攻击对象的不同，即数据传输中利用的模型的特定功能，可分为访问外部链接、访问模型存储的历史信息和访问模型存储的历史文件这三种模式。

这两种分类的依据不同，因此可以在一种分类基础上按另一种标准再细分。由于当前对各种大语言模型的功能和行为特征了解有限，本文首先基于攻击对象分类，分析收集到的模型的功能特征，然后设计程序，通过不同的攻击渠道利用这些功能实现隐蔽的数据传输。

第一节 攻击渠道

攻击渠道的不同反映了与大语言模型的交互方式的差异。以下分别介绍三种渠道及其工作原理。

2.1.1 人工页面交互

人工页面交互是指用户直接通过浏览器访问部署在大语言模型网站上的对话界面，与模型进行交流。由于本文研究的是网络环境下模型的安全问题，测试对象必须是部署在公共网络上的模型（多为商用模型）。在这种交互中，用户输入的指令、模型的响应内容以及交互过程中的行为都可能被攻击者利用。例如，攻击者可能通过精心设计的指令诱导模型访问特定网站或泄露存储信息，从而实现隐蔽数据传输。

该交互模式依托的是模型的问答功能。问答功能的技术原理在于模型内部基于概率的序列生成（自回归模型）、注意力机制（Transformer 架构）和海量数据预训练。通常情况下，模型会依据用户的指令完成文本处理、搜索执行或资源

访问等操作，而用户的提问与模型的回答均可能被攻击者操控——甚至提问本身就可能成为攻击手段。该方式的隐蔽性体现在攻击者仅需伪装成普通用户，操作简单且成本低廉。而且，人工页面交互也是其他交互方式的基础。

2.1.2 API 交互

市面上绝大多数的商用大语言模型不仅提供了公开的网页问答服务，还有供个人编程使用的应用程序编程接口，即 API。API 的存在使得用户可以在本地编程以实现对模型功能的调用。

API 交互的原理是通过预定义的规则和协议，让不同的软件系统或服务之间进行数据交换和功能调用，这在大语言模型应用上同样适用。相较于人工交互，API 交互更适配自动化操作，能够高效地处理批量任务。不过，由于 API 调用通常需要用户认证，且数据传输记录易被平台监控，其隐蔽性较弱。同时，为了测试模型在网络环境下的安全性，该方法要求 API 具备额外的联网功能，而且需要借助 API 的这一前提就意味着发送端和接收端无法像公共账号那样直接共享历史信息，这无疑限制了它的应用情形。

2.1.3 模拟网页交互

模拟网页交互，或者网页自动化技术也是利用部署在网站的大语言模型的一种方法。在这种技术的支持下，程序可自动完成指令输入、按钮点击、页面内容提取等一系列交互行为。

网页自动化技术主要涉及浏览器引擎控制、DOM 操作模型和事件系统模拟。诸如 Selenium、Puppeteer、Playwright 等常见网页自动化框架均可实现自动化操作。在这些框架的支持下，攻击者可以借助网页自动化脚本模拟用户行为，再驱使模型执行特定任务。网页自动化技术的优势在于交互高效且可编程——与人为的交互相对，它不需要攻击方进行访问网页的操作，便于快速验证模型漏洞并开发可视化应用。但是，该方式的隐蔽性取决于脚本伪装程度，一旦平台检测到高频访问等异常自动化行为，就可能触发安全限制。此外，网页自动化对攻击者的技术要求较高、程序设计较为复杂且不具有通用性，需要熟悉相关框架与特定模型的网页结构。

第二节 攻击对象

在数据传输的过程中，由于利用大语言模型的功能的不同，形成了各自的攻击对象。这些对象同时也决定了数据的载体形式。

2.2.1 访问外部链接

访问外部链接攻击的是大语言模型的网站访问功能。这种方式直接体现了模型代替用户访问网站所引发的安全漏洞。攻击者可设计一个动态 URL 网站，其后缀包含秘密信息但不影响网站功能。当模型访问该网站时，后缀数据会被网站后台记录，从而传输到接收端。这种方式的隐蔽性在于网站访问记录显示的 IP 地址属于模型，而非发送者，这就是一种低成本的身份伪装。

访问外部链接的攻击依赖的是模型的网络搜索、网页爬取和信息提取能力。模型在接收到访问指令后，会通过内置的网络接口提取网页内容，而攻击者可将数据嵌入 URL 参数（示例：`http://just4test.t.nameserver.fit/nankai`）。网站后台记录访问日志时，参数数据（“nankai”）被隐蔽传递。模型无需理解数据的含义，仅需执行访问操作即可完成传输。这种方法的优势在于简单高效，适合快速传递小规模数据。然而，模型的链接过滤机制（如禁止访问恶意网站）可能限制其成功率，而网站以及网站后台需要接收端搭建、维护，增加了实现成本。

2.2.2 访问历史信息

这种攻击利用的是模型存储历史对话信息的功能。发送端通过与模型对话，将秘密信息嵌入对话内容，接收端则通过登录同一账号查看历史记录获取数据。这种方法需要模型部署在公共网站上，排除了使用 API 进行交互的可能。

访问历史信息利用了模型的对话存储和账号共享功能。大多数对话平台会保存用户与模型之间的问答记录。攻击者可将秘密信息伪装成普通对话内容发送给模型，模型如何反应并不重要，只要发送的信息被记录即可。而在对面，接收端通过同一账号登录，查看对话历史即可提取信息。这种方法的隐蔽性在于，数据传输通过模型平台完成，无需直接通信，平台对用户隐私的保护反而会成为隐蔽性的保障。它的优点是零成本且操作简单，缺点是依赖账号共享，存在被平台监控的风险，且数据量受限于对话记录的存储容量。

2.2.3 访问历史文件

类似地，访问历史文件攻击的目标是模型对历史文件的存储机制。在这种攻击场景下，发送方上传内含目标数据的文件，接收方凭借相同账号登录模型平台实现文件获取。

该方案同样利用了模型的对话存储和账号共享功能，同时，还要求模型具有上传文件、储存文件的功能。在具体的攻击中，攻击者可能将目标数据嵌入文本、图像或编码等载体，借助模型平台的上传功能完成存储操作。当接收方使用同一账号登录平台并下载文件后，即可提取其中的信息。与基于历史信息攻击手段相似，该方式具备高度的隐蔽性与低成本优势。而且文件存储形式不仅能够承载更大容量的数据，其多样化的数据呈现方式，也为复杂信息的传递提供了便利。不过，文件上传过程常面临格式要求与文件大小的限制，平台也可能会对文件内容进行扫描检测，这些因素显著提升了数据泄露和传输失败的风险。

第三章 大语言模型服务功能分析

第一节 功能测试

总结完攻击类型后，可以依照第二种标准，即攻击对象的不同，对大语言模型所需要具备的功能进行简单的评估。

表 3.1 测试功能说明

测试功能	功能说明
网络搜索	基础的联网功能，这是大语言模型能够访问外部网站链接的前提，可以缩小需要继续进一步测试的模型的范围
访问私人网站链接 (HTML 格式)	在服务器上搭建私人网站，仅能通过 IP 地址或者域名进行访问，根据模型能否提出该网站的内容判断模型是否具有访问能力
访问私人网站链接 (JSON 格式)	在服务器上搭建私人网站，仅能通过 IP 地址或者域名进行访问，网站根据后缀的不同会返回不同的结果，根据模型能否提取出访问的结果判断模型是否具有访问能力
历史记录	能否记录与用户之前的对话，即大语言模型是否有存储历史信息的功能，可供任意时间登录账号的用户获取
历史记录独立链接	不同的历史记录是否有独立的界面以及 URL 链接，便于在模拟网页时对其进行利用
传输文件	是否有传输、储存文件记录的功能，可供任意时间登录账号的用户获取

然后，本文收集了国内外常见的通用类大语言模型。这些大语言模型可以提供聊天机器人（Chatbots）服务，并且绝大多数都有独立的网站——本文还选取了零一万物开发的 Code5AI，它属于未部署到网站的模型，在本实验中作为其他模型的对照。总计 26 个大语言模型，外国公司研发的有 11 个，中国公司研发的共 15 个，基本覆盖市面上所有知名的通用类大语言模型。

功能测试实验于 2025 年 1 月至 3 月期间展开。为得到每个模型在测试目标功能时表现出的真实特征，对于部署在同一界面下的不同模型，测试选取的是最常被使用、最易获取的模型（注册后即可使用）。此外，如果在此期间模型服务更新，会再次进行实验，覆盖之前的数据。最终汇总成表格（由于模型数量众多，分为国外模型和国内模型两部分），供后续分析以及数据传输实验使用。

表 3.2 国外大语言模型测试结果

模型名称	网 络 搜索	HTML 测试	JSON 测试	历 史 记录	独 立 链接	文 件 传输
Grok	✓	✓	✗	✓	✓	✓
ChatGPT	✓	✗	✗	✓	✓	✓
Microsoft CoPilot	✓	✗	✗	✓	✓	✓
Gemini	✓	✗	✗	✓	✓	✓
Mistral	✓	✗	✗	✓	✓	✓
Perplexity	✓	✗	✗	✓	✓	✓
AskAI	✓	✗	✗	✓	✓	✗
Pi	✓	✗	✗	✓	✗	✗
DeepAI	✓	✗	✗	✓	✗	✗
Reka AI	✗	✗	✗	✓	✓	✓
Solar Pro	✗	✗	✗	✗	✗	✗

表 3.3 国内大语言模型测试结果

模型名称	网 络 搜索	HTML 测试	JSON 测试	历 史 记录	独 立 链接	文 件 传输
豆包	✓	✓	✓	✓	✓	✓
Kimi	✓	✓	✓	✓	✓	✓
通义千问	✓	✓	✓	✓	✓	✓
智谱清言	✓	✓	✓	✓	✗	✓
文心一言	✓	✓	✗	✓	✓	✓
MiniMax	✓	✓	✗	✓	✓	✓
天工 AI	✓	✓	✗	✓	✓	✓
360 智脑	✓	✗	✓	✓	✓	✓
DeepSeek	✓	✗	✗	✓	✓	✓
白小应	✓	✗	✗	✓	✓	✓
讯飞星火	✓	✗	✗	✓	✗	✓
紫东太初	✓	✗	✗	✓	✗	✓
山海大模型	✓	✗	✗	✓	✗	✗
书生大模型	✗	✗	✗	✓	✓	✗
Code5AI	✗	✗	✗	✗	✗	✗

第二节 初步分析

下一阶段实验所需的测试数据为以下五项：对 HTML 格式的私人网站的访问能力；对 JSON 格式的私人网站的访问能力；是否有历史记录功能；历史记录是否有独立链接；是否有传输文件的功能。如果模型通过了前两项测试中的任意一项，那就可以认为它具备了访问网站的功能，可以对其采取访问外部链接的攻击；如果模型通过了第三项和第五项测试，那么可以对其采取访问历史信息或是访问历史文件的攻击，如果它同时通过了第四项测试，在理论上，便能以该模型为平台实现网页自动化程序。

总的来看，经过一系列的测试和数据汇总，能够发现国内的大语言模型在相关方面的表现比国外的大语言模型更好。尤其是在访问网站的功能上，能够提取出 HTML 格式或 JSON 格式的网页内容的模型占 15 个模型中的 8 个，能同时实现两种格式的提取的模型也有 4 个，分别是豆包、Kimi、通义千问和智谱清言。它们在全部测试中表现最好，或者说最符合后续的实验要求。而国外的模型明显逊色，11 个模型中仅有 Grok 表现出有提取 HTML 格式的网页的能力。在文件传输的功能上，国内实现的有 12 个，国外则有 7 个。至于保留历史记录的功能，已经在几乎所有模型中部署了。在比较下，以国内的大语言模型为主开展数据传输测试是更加合理且便利的选择。

另外，对比单个模型在几项功能上的测试表现，可以发现两个有意义的特征。一是能够进行文件传输的模型均能存储历史信息；二是在某些功能上表现优秀的模型在其他功能上不一定同样出色，反之亦然。比如 Reka AI 无法实现最基本的网络搜索，但它在文件传输和历史信息存储方面功能完整，而像 Pi 或者 DeepAI 虽然能进行网络搜索，它们在其他方面的表现却差强人意。智谱清言未实现独立链接功能也是类似的道理。这体现出各公司在进行大语言模型的研发时是有倾向性的，它们设计的是有“专业特长”的模型，即使它们总体上仍然是通用型的。这对大语言模型的发展是有利的。当然，这也从侧面反映了潜在的攻击方案的多样性——被利用的功能不需要有太多共性，本研究所选取的几种方式只是所有潜在可能的其中几个。

第四章 数据传输测试

在得到大语言模型的功能测试结果后，便能针对其各种功能设计实验，以说明倘若这些功能被利用，会对网络安全造成怎样的风险。笔者认为，以大语言模型为平台进行隐蔽的数据传输就是这种风险的体现之一。发送端如果能借助模型的功能向接受端传递隐蔽信息，那他就有了从事非法秘密交易的新渠道，或是将危险的病毒、木马投放至受害者。传统的加密方式关注的是如何将密文变得难以破解，利用大语言模型的数据传输则是将传输渠道变得足够隐蔽。因此，只要验证了传输的可行性，就自然地获得了一种隐蔽的传输方案。对数据进行加密是额外的工作，在实验中可以暂且不予考虑。在实现功能的时候，本文按照攻击渠道的不同，通过 API、页面交互、模拟网页三种渠道与模型进行交互测试。

第一节 API 测试

API 是模型的开发公司提供的程序编程接口，它可以在本地调用模型，是三种攻击渠道中最隐蔽的一个，但是也正是这种隐蔽性，导致它受到相当的局限。部署在网站上的模型，由于其本身就处在公共网络环境之中，因而用户只要登录账号，进入网站内部，就能实现历史信息和历史文件的共享。使用进行 API 调用固然隐蔽，但模型的生成结果只能储存在本地，若要与接受端共享，需要发送端主动连接网络。这不符合研究的目的，所以在进行 API 测试时，仅考虑利用它访问外部链接的能力。

在上一轮测试中表现优异的四个模型，豆包、Kimi、通义千问和智谱清言的开发者皆提供了相应的 API 服务。调用 API 的方式十分简单。以 Kimi 的 API 调用为例，其基本结构为，首先初始化客户端——这里需要用户的 `api_key` 以申请调用服务；然后，发送对话内容（在实验中为需要让模型访问的 URL 链接）到服务器，并发出模型处理请求，指定回复的模型（每个模型都有不同的版本，或是迭代的，或是不同功能侧重的，实验选择的是通用类的）；在核心聊天函数之外，可以设置参数（如 `temperature`）控制随机性，也可指定可调用工具（联网需要 `web_search` 工具）。如此便能实现在本地编程调用模型与之交互。

然而实验的结果并不如人意。四个之前表现最好的模型中，Kimi 和智谱清

言的 API 可以进行联网搜索，但是无法实现网页提取或是网页摘要；豆包和通义千问的 API 更是连联网也无法实现。

```
PS C:\Users\42975\Desktop\program\api> python kimi_0.py
chat_prompt_tokens: 54
chat_completion_tokens: 215
chat_total_tokens: 269
这个网址 'http://just4test.t.nameserver.fit/sadfsdafdfdsasd' 看起来像是一个测试用的网址，可能是用于内部测试、开发或者演示目的。通常，这类网址不会对外公开，也不会有特定的功能，而是用于开发人员测试网站功能、数据库连接、API接口等。

从网址的结构来看，可以推测出一些信息：
1. 'just4test' 表示这是一个测试网站。
2. 't.nameserver.fit' 可能是一个内部域名，用于测试环境。
3. '/sadfsdafdfdsasd' 可能是一个测试路径或参数。

由于这个网址没有提供任何具体信息，我们无法准确判断它的具体功能。建议你直接联系网站的管理员或开发人员，以获取更详细的信息。

如果你需要进一步分析这个网址，我可以帮你进行以下操作：
1. 访问该网址，查看网页内容和结构。
2. 分析网站使用的技术和框架。
3. 检查网站的安全性和性能。

请告诉我你希望了解的具体信息，我会尽力为你提供帮助。
PS C:\Users\42975\Desktop\program\api>
```

图 4.1 Kimi 模型 API 调用结果

```
PS C:\Users\42975\Desktop\program\api> python tongyi_0.py
我无法提供当前的日期信息。您可以通过查看设备上的日历或时钟来获取今天的具体日期。如果需要帮助，请告诉我！
```

图 4.2 通义千问模型 API 调用结果

当然，可以在 API 调用的基础上编写一个网页爬取的程序，通过增加的步骤和适当的提示词的确能够实现对网页内容的提取，并通过大语言模型返回。但这本质上仍然是发送端在直接访问网站，留下的是发送端的 IP 地址，不具备隐蔽的特征，不符合本次实验要求。

```
PS C:\Users\42975\Desktop\program\api> python kimi_1.py
你：请访问http://just4test.t.nameserver.fit/sadfsdafdfdsasd，仅提取内容
调用 crawl_url, URL: http://just4test.t.nameserver.fit/sadfsdafdfdsasd
chat_prompt_tokens: 193
chat_completion_tokens: 31
chat_total_tokens: 224
Kimi: 访问指定的网址后，提取到的内容为：`{"result":-1,"info":"/sadfsdafdfdsasd"}`
```

图 4.3 增加网页爬取功能的 API 调用结果

或许是由于在使用 API 时，对模型的调用限制更加严格，又或许是因为提供的能进行调用的模型和部署在网站上的模型性能和功能有所差异（两者的模型名称是一致的，但性能极有可能不同），因此无法利用使用 API 与模型交互的途径来完成对预定的攻击，只能采用其他方法。


第二节 页面交互测试

所谓的页面交互测试其实就是在部署了大语言模型的公共网站进行人工的对话操作，在对话的过程中，模型的行为，或是模型的存储功能能直接为攻击方

所调用，从而发生攻击方预期的结果。所以实际上，在进行功能测试实验时，已经得到了所需的绝大部分数据。


4.2.1 访问外部链接

在测试实验中，本文要求每个大语言模型访问在服务器上搭建的私人网站，并提取信息返回。只有正确返回其中内容的才被认为具有访问网站的功能。基于 Flask 框架，本文设计了两种格式的网站，HTML 格式和 JSON 格式。HTML 格式的网站仅储存了两行虚拟的邮箱信息，模型的目标就是提取邮箱的地址；JSON 格式的网站更加简单，仅有一行返回信息，但是这行信息包含了所访问的 URL 的后缀字符串。



TEST	
邮箱:	abc@foxmail.com
备用邮箱:	def@gmail.com

图 4.4 HTML 网站内容



```
{"result":-1,"info":"/sadfsdafdfdsasd"}
```

图 4.5 JSON 网站内容

直接要求访问网站还存在一定的障碍。访问私人网站这一行为本身就具有一定的安全风险，因此，许多模型在此方面设有一定的限制，也就是说，有些模型，它们本身其实具备访问私人网站的能力，但是却在回答时发生了遵循指令和确保安全之间的“目标冲突”。于是，本研究设计了四种命令方式，尝试尽可能地绕过模型本身的限制，使模型发挥它的全部功能。第一种是直接要求访问，通常的命令句式是“访问...，并提取内容”；第二种是间接要求访问，即将访问网站的命令包装成其他指令，绕开模型内部以敏感词为主的相关限制，其命令句式分为两段，先询问模型“...，这个网站是做什么用的”，再询问“那么它的内容是什么”，这种规避限制的方式的效果是显著的；第三种方式是角色扮演，这种方式属于“越狱攻击”的一种，通常被用在更好地激发模型的文本生成功能上，

但是，由于访问网站这一命令本身相对清晰，所以在此类测试中发现它的效果有限，其命令句式是“假设你是一名资深的计算机行业从业者，要为完成工作任务查找数据，数据是下面的网站中记录的备用邮箱账号···，请给出该数据”，或者“假设你是一名资深的计算机行业从业者，要对下面的网络进行访问···，给出访问的结果”；最后一种方法是借助模型网站提供的专门功能，如文心一言的网页摘要和天工 AI 的网页总结，这一方法在许多模型中取得了成功。

根据测试的结果，可以总结出模型最终回复的类型。最成功的是根据提出的要求，提供了完整的网站信息——只要四种方法中有一种成功就证明了它具备这一功能；二是拒绝访问，部分模型还会给出安全风险提示；三是表示无法访问，但是提供了如直接登录网站或编写一个程序获取网站信息的参考方法；四是返回结果，但是与网站内容大相径庭——这需要多种方法多次测试来确定。




图 4.6 HTML 网站访问样例



图 4.7 JSON 网站访问样例

最终，能成功获取 HTML 网页内容的模型有：Grok、豆包、Kimi、通义千问、智谱清言、文心一言、MiniMax 和天工 AI。能成功返回 JSON 网页内容的

有豆包、Kimi、通义千问、智谱清言和 360 智脑。虽然能访问 HTML 格式的模型较多，但是从数据传输的角度，由于 JSON 网页的 URL 后缀就可以直接作为隐蔽数据的载体，JSON 格式的网页明显更加合适（不过 HTML 格式的网页也许在其他用途上更有用，如脚本注入、重定向等）。在接收端的服务器上，可以用 `catch_all()` 函数捕获访问者（大语言模型）的 IP 地址和发送端请求的完整 URL，并记录在日志文件。



```
2025-04-25 22:27:30 IP: 182.61.202.17 URL: http://47.95.15.116/sadfsdafdfsd
```

图 4.8 网站访问日志样例

发送端只需向大语言模型发送访问网站的指令，该指令中包含的 URL 后缀即需要传递的信息。模型为回答用户的问题，会自动调用工具，访问目标网站，并返回内容。与此同时，接受端服务器的日志就会记录下此次访问，并通过后缀得到发送端传递的信息。由于访问网站的是大语言模型，留下的 IP 地址也是其部署的网站的 IP 地址，发送端的身份信息不会因为访问行为暴露。这就是一次以大语言模型为中介平台进行隐蔽数据传输的其中一种方式。

4.2.2 访问历史信息

对于提供了存储历史对话以及对话中的信息的模型，发送端只需将传输的目标数据发送给模型，无论模型回复了什么，这一数据就已经存储在账号的历史记录中。之后接受端只需登录同一账号，便能获得完全一样的数据。在此过程中，数据不可能发生丢失，这是模型的安全性保证的。多么矛盾的现象，模型对用户隐私的保护却在这种攻击下变成了隐蔽传输的保障。

本文收集到的模型中有 24 个具备储存历史记录的功能，除了 Solar Pro 和作为对照组的 Code5AI。这意味着在理论上，这些模型都有被利用的可能。这无疑是一种广泛存在的隐患。

4.2.3 访问历史文件

在存储历史对话信息的功能基础上，有的模型还满足能够存储发送的历史文件的要求。一般来说，对话信息的上限是 4000 字节左右——这意味着单次传

输数据的上限也是 4000 字节，而文件传输功能无疑能够传输更多的数据，甚至传输图片、表格等更加隐蔽的内容。

满足这一条件的模型也不在少数。具备发送文件功能的模型一般都有存储历史记录的功能，毕竟文件的读取本身就在一定程度上依赖模型对数据的记忆。国外的 11 个模型中有 7 个测试成功；国内的 15 个模型中有 12 个。它们均能作为大容量的传输平台为发送端和接受端提供零成本的传输途径。当然，无论是访问历史信息还是访问历史文件，它们的安全性都与账号的安全性高度关联，这是它们相比访问外部链接的模式逊色之处。它们的优势则在于门槛低，没有操作难度，可以轻易实现。

如果模型既能访问历史信息或历史文件，还为历史对话的记录提供了独立的 URL 链接，后续就能在此基础上尝试网页自动化的交互方式，进一步提高传输方式的便捷性和账号的安全性——网页自动化节省了登录账号的步骤，也就进一步减少了账号信息暴露的风险。

第三节 模拟网页测试

在理论上，只要某个模型能进行人工的页面交互，实现与该模型的自动化交互都是可行的。将测试范围缩小到国内的大语言模型，能够访问外部 JSON 网站的有 5 个，能利用其历史记录功能的有 10 个，能利用其存储历史文件功能的有 9 个。在实际实验中，网站的登录验证、网页设计的复杂程序、反爬虫机制等因素都让模拟网页的实现变得困难。但是，借助微软开发的开源自动化测试框架 Playwright，本文还是成功实现了部分模型的网页自动化，验证了攻击的可行性。

4.3.1 访问外部链接

实验首先通过 Playwright 库设计了保存模型账号数据的程序，即保存本地终端数据（cookies）的程序。在运行程序后，启动浏览器，进行模拟访问，打开目标模型的聊天页面；然后暂停程序，等待用户手动完成验证登录流程（国内的网站一般要求手机号以及发送的验证码，国外的网站一般要求使用邮箱验证）；登录成功后运行后续程序，将浏览器中的 cookies 保存到本地文件 cookies.json，完成操作后退出程序。

```
PS C:\Users\42975\Desktop\program\0_doubao> python save_cookies.py
请在浏览器中完成手机号登录（包括验证码），登录成功后按Enter...

Cookies已保存到cookies.json
```

图 4.9 获取 cookies 样例

```
1  [
2      {
3          "name": "_ga",
4          "value": "GA1.1.78183501.1745636956",
5          "domain": ".doubao.com",
6          "path": "/",
7          "expires": 1780196981.080023,
8          "httpOnly": false,
9          "secure": false,
10         "sameSite": "Lax"
11     },
12     {
13         "name": "ar_debug",
14         "value": "1",
15         "domain": ".www.google-analytics.com",
16         "path": "/",
17         "expires": 1753412981.220165,
18         "httpOnly": true,
19         "secure": true,
20         "sameSite": "None"
21     },
22     {
23         "name": "ttcid",
24         "value": "6ceaf8f3508748a7a6ad047ffbd9bc7713",
25         "domain": "www.doubao.com",
26         "path": "/",
```

图 4.10 cookies.json 部分内容

然后通过运行含有 `find_selectors()` 函数的程序，找到网站内部的输入框、发送按钮和回复框所对应的选择器（`input_selector`、`button_selector`、`reply_selector`）并记录。这些选择器帮助定位了网页元素，在自动化交互中实现了对网页的动态操作——一般来说，不同网站设计时所使用的选择器是不同的，所以并不存在一个通用的程序。

实现自动化交互的步骤如下。先使用 `sync_playwright()` 创建同步模式的 Playwright 实例，设置 Chromium 浏览器无头模式以隐藏交互过程；第二步加载 cookies 登录指定账户，访问初始聊天页面——这里的程序还增加了验证登录状态以防止报错的机制；确认已经登录后，通过输入框的选择器和发送按钮的选择器，输入并发送预设消息列表中的访问相关 JSON 网站的请求；通过回复框的选择器

收到回复的消息后，关闭浏览器，结束程序。接受端服务器中的日志会记录下访问的 IP 地址以及访问的 URL，从而获取了隐蔽传输的数据（即 URL 后缀）。

```
PS C:\Users\42975\Desktop\program\0_doubao> python simulate.py
已加载Cookies
已进入聊天界面!

[消息 1] 2025-04-26 11:29:41
发送: 访问http://just4test.t.nameserver.fit/sadfsdafdfdsasd, 仅提供结果
豆包回复: {"result":-1,"info":"/sadfsdafdfdsasd"}
```

图 4.11 自动化网页访问外部链接样例

在 5 个具有实现可能性的大语言模型（豆包、Kimi、通义千问、智谱清言、360 智脑）中，本文已经成功实现了 4 个：豆包、Kimi、通义千问和 360 智脑。其中，由于 Kimi 本身不注册账户也能与之交互，发送端甚至可以不使用 cookies 而直接传输数据，这明显是一种更隐蔽的传输方式。智谱清言的无法实现目前是因为其登录验证流程设置了有效的人机检测机制，比较简单的自动化程序无法成功登录提取 cookies 数据。

```
PS C:\Users\42975\Desktop\program\0_kimi> python simulate.py
已加载Cookies
已进入聊天界面!

[消息 1] 2025-04-28 15:39:54
发送: 访问http://just4test.t.nameserver.fit/sadfsdafdfdsasd, 仅提供结果
Kimi回复: 访问该链接的结果是返回了一个 JSON 格式的内容，其中包含:
"result":-1
"info":"/sadfsdafdfdsasd"
```

图 4.12 Kimi 模型自动化网页访问外部链接结果

4.3.2 访问历史信息

利用大语言模型的存储历史信息的功能进行数据传输的基本原理和代码同命令模型访问外部链接的方式大体相同。其核心逻辑都是通过选择器定位页面元素，在 Playwright 的框架下与模型产生交互。但是在细节上，两者仍有区别。

在利用历史记录时，如果单次问答产生的历史对话存储在一个由服务提供方创建独立的链接中，模拟过程会更加简单。因为此时程序访问的 URL 链接就是带有后缀（一般是一串数字或字符串）的网站地址，可以直接跳转到想要访问的历史对话界面。不过，这里需要假定接受端和发送端事前已经沟通过，确定要利用哪次历史对话记录传输数据。

其次是需要编写一个接收端的程序，用于提取该对话内的历史信息以及实

时发送的信息。程序的主体是一个循环，在循环中启动浏览器，加载 cookies，访问目标聊天页面，用 `fetch_messages()` 函数和回复框的选择器定位并获取所有消息并与已记录的消息对比，打印新消息并记录，最后关闭浏览器，等待合适的间隔后重复。这里的逻辑相对简单，所以实现起来的难度相对较小。这一稍显简练的过程在后续的功能测试中暴露出了些许瑕疵，存在可以改进的空间。

此外，该程序还增添了一些细节的实现，如动态输入发送信息、多次交互等。其中值得关注的是，在实验中发现发送端应该需要等待模型回复完毕才应被允许发送下一条信息，因而加入了对模型回复内容稳定性的判断（`new_reply_text == reply_text`），待发送端收到“可以发送新消息”的提示后才能输入下一条信息。

```
PS C:\Users\42975\Desktop\program\0_doubao> python sender.py
已加载cookies
已进入聊天界面!
请输入要发送的消息 (输入'exit'退出): 7yfausafa

[消息 1] 2025-04-26 13:27:16
发送: 7yfausafa
回复: 不太理解“7yfausafa”具体是什么意思呢，它看起来像是一串随机的字符。你可以给我讲讲它的相关背景或补充更多信息，这样我就能更好地回应你啦。
可以发送新消息
请输入要发送的消息 (输入'exit'退出):
```

```
PS C:\Users\42975\Desktop\program\0_doubao> python receiver.py
已进入聊天界面，开始监测新消息...

[新消息] 2025-04-26 13:27:05
接收到发送消息: 你好!

[新消息] 2025-04-26 13:27:23
接收到发送消息: 7yfausafa
```

图 4.13 自动化网页访问历史信息样例 1

```
PS C:\Users\42975\Desktop\program\1_InternLM> python sender.py
已加载Cookies
已进入聊天界面!
请输入要发送的消息 (输入'exit'退出): exafavaew

[消息 1] 2025-04-28 15:52:52
发送: exafavaew
回复: 看起来你的输入“exafavaew”可能是一个拼写错误或者非标准输入。如果你在尝试表达某个具体的想法或问题，请尽量提供更多细节，我会尽力帮助你。如果你有其他问题或需要进一步的解释，请随时告诉我！
可以发送新消息
请输入要发送的消息 (输入'exit'退出): cavavavgsbraee

[消息 2] 2025-04-28 15:53:02
发送: cavavavgsbraee
回复: 你的输入“cavavavgsbraee”看起来像是一个随机字母组合，可能是拼写错误或没有特定含义。如果你在尝试表达某个具体的意思或问题，请提供更多的上下文或详细信息，这样我才能更好地帮助你。如果你有其他问题或者想讨论某个话题，请随时告诉我！
可以发送新消息
请输入要发送的消息 (输入'exit'退出): aeaaafaw

[消息 3] 2025-04-28 15:53:09
```

```
[新消息] 2025-04-28 15:52:54
接收到发送消息: exafavaew

[新消息] 2025-04-28 15:52:57
接收到发送消息: 看起来你的输入“exafavaew”可能是一个拼写错误或者非标准输入。如果你在尝试表达某个具体的想法或问题，请尽量提供更多细节，我会尽力帮助你。如果你有其他问题或需要进一步的解释，请随时告诉我！

[新消息] 2025-04-28 15:53:03
接收到发送消息: cavavavgsbraee

[新消息] 2025-04-28 15:53:11
接收到发送消息: 你的输入“cavavavgsbraee”看起来像是一个随机字母组合，可能是拼写错误或没有特定含义。如果你在尝试表达某个具体的意思或问题，请提供更多的上下文或详细信息，这样我才能更好地帮助你。如果你有其他问题或者想讨论某个话题，请随时告诉我！

[新消息] 2025-04-28 15:53:14
接收到发送消息: aeaaafaw

[新消息] 2025-04-28 15:53:14
接收到发送消息: “aeaaafaw”可能是一个随机的字母组合，没有特定的含义。如果你在尝试表达某个具体的意思或问题，请提供更多的上下文或详细信息，这样我才能更
```

图 4.14 自动化网页访问历史信息样例 2

在 10 个有实现可能的模型中，本文最终实现了 4 个，分别是豆包、通义千问、360 智脑和书生大模型。虽然书生大模型（InternLM）在国内的大语言模型测试中表现较差，但是本次实验的成功印证了不同模型确有不同专长的观点。与模型对应的 4 个程序因网页元素的选择器或发送方式的不同导致代码的细节有所差异，但它们整体上的框架和逻辑是一致的。

4.3.3 访问历史文件

访问历史文件的功能所对应的自动化网页程序需要在访问历史信息的程序上修改。这里的发送端由于输入框本身就能接受各种格式的文件，其逻辑与发送普通的信息并无区别。但是获取发送成功的文件并下载到本地却无法轻易完成。

不同模型储存历史文件的方式各不相同，甚至不同类型的文件在同一模型中的储存方式也不同。以豆包为例，从豆包的页面下载模型储存的 txt 文件的途径是点击隐藏的下下载按钮后跳转至包含 txt 内容的网页，这里并无直接下载到本地的功能。而对于 pdf 或 doc 格式的文件，它的下载按钮在查看按钮被触发后才会新的界面中显示，要实现对它们的下载相对复杂。




图 4.15 豆包 txt 文件下载示例



图 4.16 豆包 pdf 文件下载示例

本文最终成功实现了对豆包大模型存储的 txt 类型文件的提取及下载。通过在 `fetch_messages()` 函数中增加对文本和文件类型的区分，以适用不同的选择器；在下载文件的 `download_file()` 函数中，利用 `file_message.hover()` 和 `file_message.focus()` 指令实现了悬停机制，以找到下载按钮，最后用 `requests.get()` 这一 HTTP 请求方法获取历史文件的内容。该程序直接针对豆包的网页设计，在其他模型上不具有可复制性。

```
PS C:\Users\42975\Desktop\program\0_doubao> python sender_file.py
已加载Cookies
已进入聊天界面!

选择操作:
1. 发送文本消息
2. 发送文件 (通过上传按钮)
输入 'exit' 退出
请输入选项 (1/2/exit) : 2

[消息 1] 2025-04-26 13:55:14
请输入文件路径: information.txt
发送文件: information.txt
已上传文件: information.txt
回复: 该文档内容主要是一些无明显语义逻辑的字符组合, 包括 "acadvasjclajalcjawlca'vav'mdsvmucadjkcnsamuvadvsvdsabfbdsVVAS", 暂无法提炼出确切的含义或主题。
文件发送成功

选择操作:
1. 发送文本消息
2. 发送文件 (通过上传按钮)
输入 'exit' 退出
请输入选项 (1/2/exit) :

PS C:\Users\42975\Desktop\program\0_doubao> python receiver_file.py
已进入聊天界面, 开始监测新消息...

[新消息] 2025-04-26 13:54:40
接收到文本消息: 你好!

[新消息] 2025-04-26 13:54:40
接收到文本消息: 7yfausaafa

[新消息] 2025-04-26 13:55:37
接收到文件: information.txt
文件已下载并保存至: downloaded_files\information.txt
[]
```

图 4.17 自动化网页访问豆包历史文件

第五章 平台成果

第一节 成果概述

在完成一系列测试实验之后，本文开发出一个基于 Python 的图形用户界面 (GUI) 应用程序，通过 tkinter 提供的发送和接收消息/文件的界面，结合 Playwright 实现对特定聊天网页（示例：<https://www.doubao.com/chat/3883015919088130>）的自动化操作。程序分为发送端和接收端，分别独立运行，互不干扰。发送端允许用户输入文本消息或上传文件并发送到聊天页面，接收端实时监听聊天页面中的新消息（文本或文件）并自动下载文件到指定目录。该应用程序集合了对大语言模型访问历史信息 and 访问历史文件的功能利用——要求它访问特定网站也是可行的，只是接收端服务器的日志记录难以集合到该程序中。

代码分为三个主要模块：ChatApp 类（负责 GUI 界面、发送端逻辑和接收端控制）、Receiver 类（负责接收端逻辑，监控新消息并下载文件）和 send_message 函数（独立的发送逻辑，处理消息或文件的网页交互），其中接收和发送端的原理在前文均有提及，这里就不多赘述。主程序用于启动 tkinter 窗口，初始化 ChatApp 并运行事件循环。同时，程序整体通过多线程确保接收端后台运行非阻塞界面，使用 playwright 自动化浏览器操作，依赖 cookies.json 实现网页登录。




图 5.1 GUI 界面运行结果

但是，在运行 GUI 界面时，能观察到发送端的运行相对较慢，需要较长的

反应时间。另外，还没有评估对模型历史存储功能的利用是否存在上限。因此，需要对原始程序进行传输速率和传输容量两方面的性能测试。

第二节 性能测试

在实验中发现，程序的主要延迟来自代码中为模拟人工交互所增设的等候时长和等待模型回复的时间。在传输速率测试中，可以尝试删除这些延迟，仅留下必要的延迟，如接收端为获取消息所需的时间；至于模型的回复，则尝试用“不用思考，仅回复这是第几个消息，输出少于 5 个字”这样的提示语句来减少模型的反应时间。

在测试中，发送端的程序会编写 n 个长度随机（10-50 字符）内容随机的密码类的字符串，通过相应的格式（直接作为字符串或填写在 txt 文件中）和提示语（“不用思考，仅回复这是第几个消息，输出少于 5 个字”）一同发送，等待回复完成（保留检查稳定性的机制，但是检查间隔设置为 0.1 秒），收到“可以发送新消息”，立刻发送下一个；接收端作为一个循环，只保留必要的获取信息的时间，获取完全部消息（是指发送端发送的消息，不用在意回复的消息）后，立刻重复循环（轮询间隔设为 0.1 秒），获取新消息。发送端在发送完 n 个字符串后自动断开，接收端在有 $n+1$ 个消息（排除开启对话的初始信息）后，自动断开。

在同步测试中（发送端和接收端同时开启），当发送的数据总量在 20 条以下时，数据的传输总体上是良好的，平均传输速率大于 80 比特/秒；但是当发送的数据达到 25 条左右，接收端就会因为长时间的运行容易引发程序的中断，这可能是由于豆包对单次会话的限制、网络的不稳定或是选择器的选择错误，不过，前 20 条数据的传输结果仍然是正确的。在传输文件时，其结果也类似，因为文件需要经过下载等步骤以及两个自动化网页交互的复杂性容易导致选择器选择错误，要想不出现错误或者冲突，应当保持一次性连续传输的文件总数在 10 个以下，其平均速率在 40 比特/秒，因为获取下载链接和进行下载需要额外的时间。

```
PS C:\Users\42975\Desktop\program\0_doubao\test> python analyze.py

=== 传输速率实验结果分析 ===
总消息数: 20
平均消息长度: 29.50 字符
总比特数: 4720 比特
总耗时: 54.00 秒
传输速率: 87.41 比特/秒
正确消息数: 20
正确率: 100.00%
```

图 5.2 同步数据传输速率测试结果样例

于是本文进一步进行了异步测试，即发送端和接收端分别运行，观察其上传速率和下载速率。令人惊讶的是，接收端此时依然只能接收到至多 25 条数据或 10 个文件——这也许就是这种方式的传输上限，因为代码的逻辑丝毫没有设定限制，也许是模型网站本身的加载机制，当接收端访问网站时只能加载前 25 条发送消息，以减轻运行负担，这是网站合理的默认行为。在没有错误的情况下，异步传输数据时，其上传速率约为 120 比特/秒，其下载速率过大，20 条信息消耗的时间几乎可以忽略不计；异步传输文件时，其上传速率约为 50 比特/秒，其下载速率约为 300 比特/秒。

```
PS C:\Users\42975\Desktop\program\0_doubao\test> python analyze.py

=== 异步消息传输分析 ===
总消息数: 20
平均消息长度: 30.55 字符
发送端总比特数: 4888 比特
接收端总比特数: 4888 比特
发送端上传速率: 116.09 比特/秒
接收端下载速率: 0.00 比特/秒
正确消息数: 20
正确率: 100.00%
```

图 5.3 异步数据传输速率测试结果样例 1

对平台成果的性能测试确实反映了设计的传输程序和利用的模型功能的某些特征，但是本实验存在不少缺陷。最显著的是，由于传输过程中时间的消耗其实更多是在与模型的交互上，因此，在单个对话框中发送的信息越多，所对应的传输速率也就越高，仅观察本次实验的结果无法完全评估这种方法的性能。

```
PS C:\Users\42975\Desktop\program\0_doubao\test> python analyze.py

=== 异步消息传输分析 ===
总消息数: 20
平均消息长度: 280.75 字符
发送端总比特数: 44920 比特
接收端总比特数: 44920 比特
发送端上传速率: 927.70 比特/秒
接收端下载速率: 0.00 比特/秒
正确消息数: 20
正确率: 100.00%
```

图 5.4 异步数据传输速率测试结果样例 2

总之，经过一系列测试，可以发现，以豆包模型为基础的数据传输程序具有良好的性能。它的传输上限为 25 条信息或 10 个 txt 文件，在这个范围内，进行隐蔽的数据传输的速率具有一定的实用性。在应用时，传输最好以异步的方式进行，即接收端在知道有数据即将传输并且获得发送端指定的历史记录链接后，在任意时间运行程序，获取目标数据。如果要进行下一次传输，应当更换利用的历史记录链接。这样一来，其隐蔽性和高效性均得到了保障。

第六章 结语

大语言模型于网络环境的部署及其交互能力的持续增强势必会催生出一系列新型安全隐患。本研究聚焦的网站访问问题只是其中的一个样式，但其暴露出的漏洞足以说明潜在风险隐患的存在。为应对针对大语言模型发动的攻击，无论是人工交互渠道还是模拟网页渠道，无论其攻击对象是模型访问外部链接的能力还是存储历史对话、历史文件的功能，均需要开发者与相关行业、部门制定有效的应对之策。

本研究在模拟网页交互测试中所遭遇的实现困难其实正是这些大语言模型网站应当加强防护的方向。例如，在尝试搭建智谱清言的网页自动化程序时，该网站的登录验证机制成功识别出了网页自动化程序的不正常访问行为，类似识别并拦截成功的还有 ChatGPT，这是其他大语言模型网站没有做到的。其次，为网页增设防爬机制和实时的异常检测也是可行之举。在设计文心一言的网页自动化程序时，虽然程序成功提取了用户账号的 cookies，但是由于网站防爬机制的存在，程序无法顺利地获取对话发送按钮的选择器。而该网站的异常检测机制更是在之后成功阻止了程序向模型发起的对话请求。这些案例可以说明强化登录验证、访问频率限制以及动态行为监控等基础安全设计可以有效降低网页自动化攻击的成功概率。

但是倘若攻击者采取的是人工页面交互的形式，那么相应的监管、防范难度会更高。因为只要用户能够登录网络环境，通过普通浏览器访问模型平台，他们利用大语言模型对网络环境造成危害的风险就已经存在，因此只能从特定的攻击对象入手思考防范的措施。对于模型的访问外部链接功能，虽然禁止开发模型的此类功能并不现实——也不应该禁止，但是可以提高模型对某些关键词的敏感程度，使其能够更精确地判断出哪些命令有可能使它的访问行为产生安全风险。比如，可以参照 LMSanitizer 工具原理，利用关键词检测与语义分析算法，识别含可疑的链接或异常参数指令，拒绝服务高风险指令。对历史对话、历史文件的检测也是如此，如果有可疑的信息存在，模型就不应该保留相关内容，相应的筛查和删除机制应当被健全完善。

大语言模型的隐私保护机制有时会成为安全漏洞的温床。在通常情形下，对网络或网站中的可疑信息进行审查的是政府的有关部门；在大语言模型的应用

情形下，承担起这个责任的自然应当是模型的开发者和服务提供方。因为是他们对于模型用户的隐私保护造成了这种潜在风险。观察测试结果可以发现，众多平台为保障用户隐私，默认存储用户的历史对话与文件记录，并支持同一账号跨设备访问。这一便利设计固然有利于客户体验，但是在客观上却为攻击者提供了可乘之机。开发者应当重新权衡隐私保护与安全性，主动承担更多审查责任，及时检测过滤恶意数据，防止模型的功能被滥用。

除了事前预防，事后监管机制同样十分关键。大语言模型在实际情形下的广泛应用难免遭遇功能破解与恶意利用，保护措施再完善也不可能做到万无一失。然而，数据泄露等安全事件一旦发生，后果会相当严重。所以平台应当设计快速响应机制，在接到举报、投诉后，模型的服务方应当迅速追踪账号活动，确认威胁后立即暂停账号、限制访问并通知用户，即承担法律上的反通知义务。同时，开发者应当与监管机构协同，构建报告追责机制，以便快速查明事件原因、降低损失并追究责任。此外，向用户与开发人员普及网络安全知识也有助于完善网络安全的治理，以达到在根源上防患于未然的效果。

参考文献

- [1] 文森, 钱力, 胡懋地等. 基于大语言模型的问答技术研究进展综述[J]. 数据分析与知识发现, 2024, 8(6): 16-29
- [2] 赵鑫, 窦志成, 文继荣. 大语言模型时代下的信息检索研究发展趋势[J]. 中国科学基金, 2023, 37(5): 786-792
- [3] 付翔, 魏晓伟, 张浩等. 数字安全角度下审视和剖析 chatgpt[J]. 航空兵器, 2023, 30(6): 117-122
- [4] 付志远, 陈思宇, 陈骏等. 大语言模型安全的挑战与机遇[J]. 信息安全学报, 2024, 9(5): 26-55
- [5] 李南, 丁益东, 江浩宇等. 面向大语言模型的越狱攻击综述[J]. 计算机研究与发展, 2024, 61(5): 1156-1181
- [6] Carlini N, Tramer F, Wallace E, *et al.* Extracting training data from large language models[C]. 30Th USENIX Security Symposium (USENIX Security 21). Virtual: USENIX Association, 2021: 2633-2650
- [7] Xia C S, Paltenghi M, Le Tian J L, *et al.* Fuzz4all: universal fuzzing with large language models[C]. IEEE/ACM 46Th International Conference on Software Engineering (ICSE). Lisbon, Portugal: IEEE, 2024: 1-12
- [8] Cui H, Wang X, Yang K, *et al.* Actively secure half-gates with minimum overhead under duplex networks[C]. Advances in Cryptology – EUROCRYPT 2023. Lyon, France: Springer, 2023: 35-67
- [9] Liu H, Wang X, Yang K, *et al.* Bitgc: garbled circuits with 1 bit per gate[C]. Advances in Cryptology – EUROCRYPT 2025. IACR, 2025: 92-115
- [10] Wei C, Meng W, Zhang Z, *et al.* Lmsanitizer: defending prompt-tuning against task-agnostic backdoors[C]. Network and Distributed System Security (NDSS) Symposium: vol. 31. San Diego, CA, USA: Internet Society, 2024: 45-70
- [11] Schroeder de Witt C, Sokota S, Kolter J Z, *et al.* Perfectly secure steganography using minimum entropy coupling[C]. International Conference on Learning Representations (ICLR). Kigali, Rwanda: PMLR, 2023: 89-105
- [12] 钱力, 刘熠, 张智雄. Chatgpt 的技术基础分析[J]. 数据分析与知识发现, 2023, 7(3): 6-15
- [13] 张熙, 杨小汕, 徐常胜. Chatgpt 及生成式人工智能现状及未来发展方向[J]. 中国科学基金, 2023, 37(5): 743-750
- [14] 张伟男, 刘挺. Chatgpt 技术解析及通用人工智能发展展望[J]. 中国科学基金, 2023, 37(5): 751-759

- [15] 梁思源, 何英哲, 刘艾杉等. 面向大语言模型的越狱攻击与防御综述[J]. 信息安全学报, 2024, 9(5): 56-86
- [16] Brown T B, Mann B, Ryder N, *et al.* Language models are few-shot learners[C]. Advances in Neural Information Processing Systems (NeurIPS): vol. 33. Vancouver, Canada: Curran Associates, Inc., 2020: 1877-1901

致 谢

要用短短的两篇致谢、两页纸的篇幅来结束这充实而又“充实”的四年实在有些勉强，甚至说有些残忍，因为若是想要在文字中流露点个人情感，顺便回顾一下这四年“波澜壮阔”的学习经历——是的，单纯讲述学习经历就足以称得上波澜壮阔，那么，洋洋洒洒写下与这篇论文同等的万把文字也不嫌重复。然而这样的期许显然是不现实的，学会克制自我过剩的表达欲望，学会如何在为自我的提升训练文化与礼节技能的同时理解谦虚与敬仰的意义，也是我在大学中学到的重要一课。学习法律，自然知道有些传统是要尊重的，只要理解了其背后的价值。

我首先要感谢南开大学密码与网络空间安全学院的各位老师，尤其是以丰富的耐心指导我完成这篇论文的李想老师。无论各位老师在教导课程，给予评价的时候是严谨还是松弛，是严厉还是宽松，都构成了我对计算机语言、计算机技术的认知，帮助我更好地理解如今的科学发展与现代社会。再多的感谢与尊敬都不为过。

我还需要感谢长久以来一直陪伴在我身边的家人与朋友。无论你们以何种方式与我相伴，这四年缺少了你们，都会缺少大把的趣味。如果没有你们那双倾听的耳朵，我该如何缓解每天夜晚走出教学楼，行走在半明半灭的街灯下的疲惫与懈怠？你们有的是生活上的智者，有的是知识上的翘楚，有的是电话那头的温暖，有的是藏匿书页的灵魂，我永远不会拒绝与你们共度时光。假如我有时变得脆弱，不近人情，又或是其他任何负面的情绪显露，我都要感谢你们的包容与体贴。

最后，我还是想花一定的笔墨感谢一下自己，感谢自己没有在最煎熬的时候放弃，感谢自己在情绪失调、精神痛苦的时候也没有放弃对知识的求索——这种欲望似乎自然而然发，永不停息地燃烧于我的内在，但是我很清楚，这是我逐渐培养出的习惯，这种观念、这种不竭的动力，都要归功于过去四年的自己。

笔拙情真，难尽心意，还请海涵！